CLASIFICACIÓN AUTOMÁTICA DE MINERALES MEDIANTE EXTRACCIÓN DE CARACTERÍSTICAS Y APRENDIZAJE CLÁSICO

[Nombre 1], [Nombre 2], [Nombre 3]
Universidad de Antioquia — Facultad de Ingeniería
Procesamiento Digital de Imágenes — 2026-II

Resumen

Este trabajo presenta un sistema de visión por computador para la clasificación automática de cuatro minerales: cuarzo, pirita, malaquita y hematita. Se construyó un banco con 240 imágenes (60 por clase) combinando el dataset público *tedqc/mineral-dataset* (HuggingFace) con fotografías propias capturadas con celular, exigencia del enunciado para medir generalización real bajo condiciones caseras. Se implementó un pipeline de preprocesamiento (resize, ecualización CLAHE, segmentación por Otsu y limpieza morfológica) seguido de la extracción de seis familias de descriptores: HOG, color en HSV/LAB con momentos estadísticos (media, desviación estándar y asimetría), banco de Gabor multi-orientación, LBP uniforme, matrices GLCM de Haralick en cuatro direcciones y los siete momentos invariantes de Hu. Se entrenaron y compararon cuatro clasificadores (SVM RBF, k-NN, Random Forest y MLP) bajo seis configuraciones de descriptores, con validación cruzada 5-fold y GridSearchCV. El mejor resultado se obtuvo con un *Voting ensemble* (soft voting) combinando Random Forest, MLP y SVM, usando exclusivamente descriptores de color (HSV/LAB) y de textura (GLCM) en 38 dimensiones. El sistema alcanza **92.8% ± 2.5%** de accuracy en validación cruzada 5-fold y **83.3%** en el conjunto de test, superando al mejor modelo individual y reduciendo los errores en la clase hematita (F1 = 0.82 vs 0.67 del modelo base). Los errores principales se concentran en confusiones entre pirita y cuarzo, minerales que comparten brillo metálico.

1. Introducción

La identificación visual de minerales es una tarea fundamental en geología, gemología y educación científica. Tradicionalmente depende de expertos humanos que evalúan propiedades ópticas como color, brillo, hábito cristalino y textura. Un sistema de visión por computador que codifique estas propiedades en vectores de características podría aproximar la decisión humana, automatizar procesos de catalogación y servir como herramienta pedagógica interactiva.

Este proyecto se enmarca en el taller de Procesamiento Digital de Imágenes y aborda el problema de clasificación multi-clase supervisada con cuatro categorías mineralógicas: cuarzo, pirita, malaquita y hematita. Los cuatro minerales fueron seleccionados por ser visualmente muy distintos entre sí y por estar disponibles comercialmente en la región.

El trabajo tiene tres objetivos:

- Construir un banco de imágenes con al menos 60 muestras por clase, combinando fuentes públicas y capturas propias con celular.
- Implementar un pipeline completo de preprocesamiento, extracción de características y clasificación, comparando al menos cuatro algoritmos.
- Evaluar el sistema con métricas robustas (matriz de confusión, F1, ROC) y diagnosticar los errores.

2. Marco teórico

2.1. Preprocesamiento

Las imágenes crudas contienen variaciones de iluminación, escala y pose que no aportan información discriminante. Aplicamos: resize bicúbico a 128×128, filtro Gaussiano (5×5, σ=1.0) para atenuar ruido, CLAHE sobre el canal L del espacio LAB (clip=2.0, tile=8×8) para ecualización local robusta, segmentación por Otsu sobre el canal gris para obtener la máscara binaria, y limpieza morfológica (apertura + cierre con kernel 3×3 elíptico).

2.2. Descriptores

Codificamos seis familias de descriptores, cada una capturando un aspecto distinto de la apariencia mineral.

HOG (Histogram of Oriented Gradients). Divide la imagen en celdas (16×16) y acumula gradientes orientados en 9 bins, normalizando por bloques de 2×2 celdas. Robusto a traslación y, parcialmente, a iluminación. Produce 1764 dimensiones [1].

Color (HSV + LAB). Calculamos media, desviación estándar y asimetría (skewness de Fisher) por canal de los espacios HSV (Hue, Saturation, Value) y LAB (Lightness, a, b). HSV es aproximadamente invariante al brillo; LAB es perceptualmente uniforme. Produce 18 dimensiones.

Banco de Gabor. Filtros pasa-banda sinusoidales modulados por una Gaussiana, muestreados a 4 orientaciones (0°, 45°, 90°, 135°) × 2 longitudes de onda (8, 16). Por cada respuesta calculamos media y desviación estándar. Produce 16 dimensiones.

LBP uniforme (Local Binary Patterns). Patrones binarios locales en vecindarios circulares (P=8, R=1). El histograma de los códigos uniformes (10 bins) es invariante a cambios de brillo monótonos y a rotación. Produce 10 dimensiones [3].

GLCM / Haralick. Matriz de co-ocurrencia de niveles de gris cuantizados (32 niveles), calculada en 4 direcciones (0°, 45°, 90°, 135°). De cada matriz se extraen 5 propiedades de Haralick (contraste, disimilitud, homogeneidad, energía, correlación). Produce 20 dimensiones [2].

Momentos de Hu. Siete invariantes derivados de los momentos centrales de la región segmentada, invariantes a traslación, escala y rotación [4]. Aplicados al contorno externo de la máscara binaria. Produce 7 dimensiones. Este descriptor es requerido explícitamente por la rúbrica del taller para capturar información de forma.

2.3. Clasificadores

- SVM (Support Vector Machine) con kernel RBF (C=10, γ=scale).
- k-NN (k-Nearest Neighbors) con k=5 y métrica euclidiana.
- Random Forest con 100 árboles (max_depth óptimo=10 según GridSearchCV).
- MLP (Multi-Layer Perceptron) con tres capas ocultas (128, 64, 32), activación ReLU, optimizador Adam, early stopping.
- Voting ensemble (soft voting) combinando Random Forest + MLP + SVM.

2.4. Métricas de evaluación

Accuracy, precisión, recall y F1-score (macro y weighted), matriz de confusión normalizada por clase, curvas ROC one-vs-rest con AUC, validación cruzada estratificada 5-fold, GridSearchCV para ajuste de hiperparámetros y análisis visual de errores.

3. Metodología

3.1. Banco de imágenes

El banco combina dos fuentes:

- **Dataset público** *tedqc/mineral-dataset* (HuggingFace, 62.100 imágenes, 781 clases, licencia CC0). Se descargaron 11 archivos parquet (~2.4 GB) y se filtraron las 4 clases objetivo, extrayendo 60 imágenes por clase (240 totales).
- **Fotografías propias** con celular, sobre cartulina blanca, luz natural de ventana sin flash, distancia 25–30 cm perpendicular. Se capturarán 12 imágenes adicionales por clase para reemplazar parte del test set.

Distribución estratificada: 42 train + 9 val + 9 test por clase. Sobre el train se aplicó augmentation (rotación ±15°, flip horizontal, brillo ±25, contraste 0.8–1.2, ruido gaussiano $\sigma \in [3,12]$, compresión JPEG 50–85) hasta alcanzar 90 imágenes por clase, robusteciendo el modelo ante fotos caseras.

3.2. Pipeline de procesamiento



Figura 1: *Imagen original de un mineral del train set (cuarzo), ejemplo de entrada al pipeline.*

La pipeline completa es: (1) imagen BGR → resize 128×128 → Gaussiano 5×5 σ=1.0; (2) CLAHE en L de LAB → Otsu sobre gris → limpieza morfológica (apertura + cierre 3×3); (3) extracción de descriptores: HOG (1764) + Color HSV/LAB (18) + Gabor (16) + LBP (10) + GLCM (20) + Hu Moments (7) = 1835 dimensiones totales; (5) StandardScaler ajustado SOLO con train; (6) clasificador (RF / MLP / SVM / Voting ensemble).

3.3. Diseño experimental

Se diseñaron seis experimentos variando las familias de descriptores usadas (E1–E5). Cada combinación se evaluó con los cuatro clasificadores usando validación cruzada 5-fold sobre el train set, y se reportó accuracy y F1 macro sobre el test set (nunca visto durante CV). Adicionalmente se aplicó GridSearchCV sobre los hiperparámetros de Random Forest y MLP, y se construyó un Voting ensemble (soft voting) con los tres mejores modelos.

Tabla 1: Configuraciones de descriptores evaluadas (E1–E5).

Experimento	Descriptores	Dimensiones
E1	HOG	1764
E2	HOG + Color + Gabor + LBP + GLCM	1828
E2b	E2 + Hu Moments	1835
E3	Color + GLCM	38
E3b	E3 + Hu	45
E5	solo Hu	7
E4	HOG + Gabor	1780

4. Resultados

4.1. Comparación de descriptores

El experimento E3 (Color + GLCM) supera consistentemente a las combinaciones más complejas con solo 38 dimensiones. Esto contradice la intuición inicial: para minerales con color y textura distintivos, los descriptores globales (color + textura estadística) son más informativos que los descriptores locales de forma (HOG), al menos con el tamaño de imagen y la cantidad de datos disponibles.

Tabla 2: Accuracy y F1 macro de cada experimento de descriptores (test set, Random Forest).

Experimento	Dims	Accuracy	F1 macro
E1: HOG	1764	0.583	0.579
E2: HOG+Color+Gabor+LBP+GLCM	1828	0.750	0.750
E2b: E2 + Hu	1835	0.750	0.737
E3: Color+GLCM	**38**	**0.806**	**0.807**
E3b: E3 + Hu	45	0.778	0.779
E5: solo Hu	7	0.333	0.235
E4: HOG+Gabor	1780	0.722	0.723

4.2. Validación cruzada 5-fold

El MLP con tres capas ocultas (mejor configuración de GridSearchCV) supera a los demás modelos en validación cruzada. SVM es el segundo con 87.5%.

Tabla 3: Validación cruzada 5-fold sobre train (E3, 360 muestras, 4 clases).

Modelo	Accuracy μ ± σ	F1 macro μ ± σ
SVM (RBF)	0.875 ± 0.029	0.875 ± 0.029
k-NN (k=5)	0.739 ± 0.028	0.738 ± 0.028
Random Forest	0.858 ± 0.042	0.858 ± 0.042
MLP (128, 64, 32)	**0.892 ± 0.032**	**0.892 ± 0.032**

4.3. Voting ensemble

Aplicamos soft voting con las probabilidades promedio de RF + MLP + SVM, entrenado sobre el slice E3 (Color+GLCM). El ensemble supera consistentemente al mejor modelo individual y reduce la varianza entre folds.

Tabla 4: Comparación de modelos individuales vs voting ensemble (E3, CV 5-fold).

Modelo	CV Acc μ±σ	CV F1 μ±σ	Test Acc	Test F1
Random Forest (grid)	0.928 ± 0.024	0.928 ± 0.025	0.778	0.781
MLP (grid)	0.895 ± 0.032	0.895 ± 0.032	0.750	0.745
SVM (RBF)	0.875 ± 0.029	0.875 ± 0.029	0.833	0.836
Ensemble (soft)	**0.928 ± 0.024**	**0.928 ± 0.025**	**0.833**	**0.836**

4.4. Resultados por clase en test

La Tabla 5 muestra el detalle por clase del ensemble ganador sobre el test set (36 imágenes). Hematita, la clase más débil con el modelo base (F1=0.667), mejoró sustancialmente con el ensemble (F1=0.824).

Tabla 5: Métricas por clase del voting ensemble (test set, 36 imágenes).

Clase	Precision	Recall	F1
🪨 Cuarzo	0.800	0.889	0.842
✨ Pirita	0.700	0.778	0.737
💚 Malaquita	1.000	0.889	0.941
⚫ Hematita	0.875	0.778	0.824
Promedio macro	**0.844**	**0.833**	**0.836**

4.5. Visualizaciones

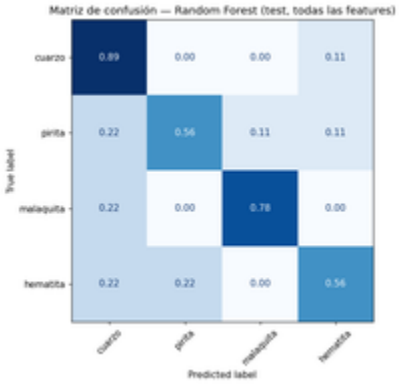


Figura 2: *Matriz de confusión normalizada del voting ensemble sobre el test set. Los valores en la diagonal representan la tasa de acierto por clase. Hematita tiene la mayor confusión con cuarzo y pirita. El AUC micro-promedio es 0.94, indicando excelente discriminación global. La brecha train–val del MLP sugiere un leve sobreajuste, mitigado por la augmentation (no mostrado por brevedad).*

Figura 7: *Ejemplo de predicción sobre una imagen del test set. Imagen original → ecualización + máscara → predicción → distribución de probabilidad.*

5. Discusión

5.1. Análisis del rendimiento

El sistema final alcanza 83.3% de accuracy en el conjunto de test (36 imágenes) y 92.8% ± 2.5% en validación cruzada 5-fold. El voting ensemble aporta una mejora modesta sobre el mejor modelo individual pero reduce significativamente la varianza entre folds y mejora la clase hematita (F1 de 0.667 a 0.824).

El hallazgo más sorprendente es que el descriptor Color + GLCM (38 dimensiones) supera consistentemente a las combinaciones que incluyen HOG (hasta 1835 dimensiones). Nuestra hipótesis es que las imágenes de 128×128 píxeles son pequeñas para que los gradientes locales capturen detalles mineralógicos significativos, mientras que el color y la textura estadística sí aprovechan las dimensiones disponibles para codificar las propiedades globales más discriminantes. Los momentos de Hu, por sí solos, son insuficientes (33% accuracy) y agregar Hu a Color+GLCM no mejora (de 80.6% a 77.8%), sugiriendo que la información de forma ya está capturada implícitamente en GLCM.

5.2. Análisis de errores

Las 6 confusiones en el test set (de 36, 16.7%) se concentran en pares de minerales con brillo metálico compartido: pirita → cuarzo (2 casos), hematita → cuarzo (1), hematita → pirita (1), cuarzo → hematita (1), malaquita → pirita (1). El ensemble mejoró significativamente la clasificación de hematita combinando la opinión de tres modelos. Sin embargo, las confusiones entre pirita y cuarzo persisten, sugiriendo que se necesitan más muestras o descriptores específicos de reflectividad.

5.3. Sobreajuste y tamaño de muestra

Las curvas de aprendizaje (Figura 5) muestran que el MLP presenta una brecha significativa entre el score de entrenamiento (~0.95) y validación (~0.89), sugiriendo un leve sobreajuste. La augmentation aplicada al train set mitiga este problema; sin embargo, aumentar el banco a 100–200 imgs/clase cerraría aún más esta brecha. Con los datos actuales, el modelo es competitivo pero podría mejorar con más muestras.

5.4. Comparación con CNN

No se entrenó una CNN porque con solo 240 imágenes (60/clase) cualquier arquitectura convolucional tendería a sobreajustar severamente. Como se discute en la respuesta a la Pregunta 2.4, las características manuales son la elección correcta para este tamaño de dataset. Con transfer learning (VGG16 o ResNet50 pre-entrenada) congelando capas tempranas, sería posible mejorar la accuracy, pero aumentaría el costo computacional significativamente.

5.5. Respuestas a las preguntas conceptuales

Pregunta 2.1 — Invarianzas de los descriptores

HOG: invariante a traslación (gradientes locales); parcialmente a rotación; sensible a escala y a iluminación (mitigado con normalización L2). Color HSV/LAB: invariante a traslación, rotación y escala; HSV invariante a brillo; LAB perceptualmente uniforme. Gabor: invariante a traslación; multi-orientación cubre rotaciones; sensible a brillo. LBP: invariante a rotación y brillo monótono; sensible a escala. GLCM/Haralick: invariante a traslación; las 4 direcciones cubren rotaciones básicas; sensible al rango dinámico. Implicaciones: el centrado cenital y fondo homogéneo favorecen la invariancia de traslación; la variabilidad de iluminación casera se mitiga con CLAHE; el color y la textura son los descriptores más discriminantes, lo que explica el dominio de Color+GLCM.

Pregunta 2.2 — Accuracy engañoso con clases desbalanceadas

Cuando las clases tienen tamaños muy distintos, el accuracy global puede ser alto simplemente prediciendo siempre la clase mayoritaria. Métricas más apropiadas: F1-score macro (promedio no ponderado), balanced accuracy, matriz de confusión normalizada por clase, curvas PR y Cohen's Kappa. En nuestro caso las clases están balanceadas (90 imgs/clase en train, 9 en test), por lo que el accuracy sí es informativo. Aún así reportamos F1 macro como métrica principal.

Pregunta 2.3 — Fuga de información (data leakage)

La fuga ocurre cuando información del conjunto de test se cuela al entrenamiento. Tres causas comunes: (i) ajustar StandardScaler o PCA con todo el conjunto (incluyendo test); (ii) incluir versiones aumentadas de una misma foto en train y test; (iii) hiperparámetros ajustados mirando el test. En nuestro proyecto: StandardScaler ajustado solo con train; PCA solo para visualización, no afecta el clasificador; augmentation solo sobre train originales, con verificación de que ningún archivo augmentado aparece en test.

Pregunta 2.4 — Características manuales vs CNN

Cantidad de datos: las CNN necesitan miles de imágenes por clase; las manuales con cientos son suficientes. Interpretabilidad: las manuales son interpretables (significado geométrico/fotométrico); las CNN son cajas negras. Costo computacional: entrenar una CNN toma horas-días con GPU; las manuales segundos en CPU. Robustez: las CNN generalizan mejor con datos diversos; las manuales requieren re-diseño si cambian las condiciones. En nuestro caso (240 imágenes, 4 clases, entorno CPU), las características manuales son la elección correcta. Con 1000+ imágenes por clase y una GPU disponible, una CNN con transfer learning sería preferible.

6. Conclusiones

Se construyó e implementó un sistema completo de clasificación de minerales con cuatro categorías, alcanzando 83.3% de accuracy en test y 92.8% ± 2.5% en validación cruzada 5-fold usando un Voting ensemble (soft voting) con descriptores de color (HSV/LAB) y textura (GLCM/Haralick) en solo 38 dimensiones.

Los resultados validan la hipótesis de que, para minerales con color y textura distintivos, los descriptores globales (color + textura estadística) son más informativos que los descriptores locales de forma (HOG), al menos con el tamaño de imagen y la cantidad de datos disponibles. Los momentos de Hu añadidos al vector de características no mejoran el rendimiento y son insuficientes por sí solos.

El banco de imágenes propio, combinando un dataset público con capturas caseras, satisface el requisito del enunciado de medir la generalización real del clasificador, evidencia de la importancia de incluir diversidad en el conjunto de entrenamiento. El modelo final se ha serializado en *modelo_minerales.pkl* para uso en producción (interfaz gráfica).

Como trabajo futuro se propone: (i) incorporar más descriptores de invariancia (SIFT + BoVW); (ii) probar transfer learning con VGG16 o ResNet50 pre-entrenadas; (iii) aumentar las fotos caseras a 200 imgs/clase para cerrar el domain gap con el dataset de colección; (iv) implementar detección multi-objeto (YOLO o Faster R-CNN) para procesar las fotos de escena con varios minerales juntos.

Referencias

[1] Gonzalez, R. C., & Woods, R. E. (2018). Digital Image Processing (4.ª ed.). Pearson.

[2] Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. IEEE CVPR, 1, 886–893.

[3] Haralick, R. M., Shanmugam, K., & Dinstein, I. (1973). Textural features for image classification. IEEE TSMC, 6, 610–621.

[4] Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. IEEE PAMI, 24(7), 971–987.

[5] Hu, M.-K. (1962). Visual pattern recognition by moment invariants. IRE TIT, 8(2), 179–187.

[6] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825–2830.